

Labo 8 – Solutions

204.1 Signal et information

Partie 0 - Alphabet de départ

$A = ('A', 'D', 'E', 'I', 'M', 'N', 'P', 'R', 'U', 'Y')$.

1. $p \approx (0.12, 0.02, 0.06, 0.20, 0.11, 0.08, 0.11, 0.08, 0.10, 0.11, 0.01)$.
2. $H(X) \approx 3.21$.

Partie 1 - Code préfixe “naïf”

1. Mon alphabet à encoder est composé de 10 symboles. Afin d’avoir au moins 10 combinaisons distinctes de symboles binaires, je dois utiliser 4 symboles. En effet, avec 3 symboles, je peux faire $2^3 = 8$ “mots” différents, ce qui n’est pas suffisant. Avec 4 symboles, je peux faire $2^4 = 16$ “mots”.
2. Une possibilité de code préfixe “naïf” (pas unique) :

X	A	D	E	I	M	N	P	R	U	Y
$C_1(X)$	0000	0001	0010	0011	0100	0101	0110	0111	1000	1001

3. Comme tous les symboles de A sont encodés avec le même nombre de bits, la longueur moyenne se calcule directement $\mathbb{E}(\ell(C_1(X))) = 4.0$.

Partie 2 - Code de Fano

1. On commence par construire l’arbre :




Figure 1: Arbre d’encodage de Fano pour mon alphabet

L’encodage de l’alphabet est donc :

X	A	D	E	I	M	N	P	R	U	Y
$C_2(X)$	010	0110	000	110	0111	111	1000	101	1001	001

2. Si on note $\ell(C)$ la longueur d'un mot C , on calcule l'espérance de la longueur du code d'un caractère aléatoire comme

$$\mathbb{E}(\ell(C_2(X))) = \sum_{a \in A} \ell(C(a))p(X = a) \approx 3.25 > 3.06.$$

Partie 3 - Code de Shannon

1. Le tableau ci-dessous donne, pour chaque symbole, sa probabilité, la longueur du code $\ell(C_3(a))$, la valeur de sa fonction de distribution cumulative, le développement en binaires de sa fonction de distribution cumulative et son code de Shannon.

X	E	A	I	N	R	U	D	M	P	Y
p_i	0.23	0.14	0.13	0.12	0.12	0.09	0.07	0.05	0.05	0.01
ℓ	3	3	3	4	4	4	4	5	5	7
c_i	0.00	0.23	0.37	0.50	0.62	0.74	0.82	0.90	0.94	0.99
Bin.	0.000000000	0.001110110	0.010111100	0.011111110	0.100111100	0.101111000	0.110100100	0.111001000	0.111100010	0.11111101
$C_3(X)$	000	001	010	0111	1001	1011	1101	1110	11110	1111110

2. L'espérance de la longueur du code d'un caractère aléatoire donne

$$\mathbb{E}(\ell(C_3(X))) = \sum_{a \in A} \ell(C(a))p(X = a) \approx 3.63 > 3.06.$$

Partie 4 - Code de Lempel-Ziv

Mes paragraphes sont les 18, 4 et 23, reproduits dans le fichier *lab08-solution-myLoremIpsum.txt* :

Le code obtenu est donné dans le fichier *lab08-solution-myCode.txt*.

Discussion

- J'obtiens un encodage en **2046** caractères alors que le texte initial en faisait **1842**. Le taux de compression est donc d'environ 111%. Ce n'est donc pas vraiment une compression. Il faudrait un texte beaucoup plus long, ou avec plus répétitions pour atteindre un bon taux de compression.
- Pour décoder Lempel-Ziv, on va peupler récursivement le tableau ci-dessus en lisant l'alternance entre adresse et symbole que l'on a dans le code.
- L'avantage principal de Lempel-Ziv est que l'encodage s'adapte naturellement à la fréquence des symboles dans le texte à encoder. Cela donne donc un encodage optimal **pour le message à encoder**, alors que Huffman donne un encodage optimal en supposant les fréquences connues d'avance.
 - De plus, Lempel-Ziv optimise sur les répétitions de suites de symboles. Ainsi, en français, les séquences "la" ou "le" sont très fréquentes, ce qui est naturellement pris en compte par Lempel-Ziv.

3. L'encodage de Lempel-Ziv contient lui-même, par construction, sa propre table d'encodage. Avec le code de Huffman, on doit s'accorder en avance sur l'encodage de notre alphabet, ce qui n'est pas nécessaire pour Lempel-Ziv.
4. Par sa nature, l'encodage de Lempel-Ziv permet une compression sans connaître le message à encoder à l'avance. Il est donc adapté a une compression de donnée "en direct".